

Обоснование стратегии оптимизации Q-функции

13 октября 2025 г.

0.1. Правдоподобие смеси

Допустим мы имеем независимые наблюдения $x_1, \dots, x_n$ полученные из смеси распределений.

Плотность смеси распределений имеет следующий вид:

$$f(x \mid \Psi) = \sum_{i=1}^k \omega_i \cdot f_i(x \mid \theta_i)$$

где Ψ — вектор параметров смеси ω_i, θ_i, f_i — i -ая компонента смеси.

Правдоподобием смеси распределений при наблюдаемых данных будет называться функция [1] (см. уравнение 2.2):

$$\mathcal{L}(x \mid \Psi) = \prod_{i=1}^n f(x_i \mid \Psi) = \prod_{i=1}^n \left(\sum_{j=1}^k \omega_j \cdot f_j(x_i \mid \theta_j) \right)$$

Для оценки параметров достаточно максимизировать правдоподобие. В силу монотонности логарифма можно оптимизировать логарифм правдоподобия [1] (см. уравнение 2.19):

$$\ln \mathcal{L}(x \mid \Psi) = \sum_{i=1}^n \ln \left(\sum_{j=1}^k \omega_j \cdot f_j(x_i \mid \theta_j) \right)$$

Однако данную вещь неудобно оптимизировать из-за присутствия логарифма суммы, поэтому мы делаем дополнительное предположение, начиная работать с так называемыми ”полными данными”.

0.2. Правдоподобие полных данных

Пусть мы имеем независимые наблюдения (x_i, z_i) , где x_i — элементы выборки, а z_i — компонента к которой этот элемент принадлежит. Функцией правдоподобия для полных данных, мы будем называть:

$$\mathcal{L}_c(x, z \mid \Psi) = \prod_{i=1}^n \mathbb{P}(x_i, z_i = j \mid \Psi)$$

Совместную вероятность внутри произведения можно расписать по цепному правилу:

$$\mathbb{P}(x_i, z_i = j \mid \Psi) = \mathbb{P}(x_i \mid z_i = j, \Psi) \cdot \mathbb{P}(z_i = j \mid \Psi)$$

Понятно, что если i -ое наблюдение принадлежит j -ой компоненте, то $\mathbb{P}(z_i = j \mid \Psi) = \omega_j$, а вероятность $\mathbb{P}(x_i \mid z_i = j, \Psi)$ описывается функцией плотности $f_j(x_i \mid \theta_j)$.

Можно представить z_i как вектор из нулей и одной единицы, стоящей на j -ом месте: $z_i = (z_{i1}, \dots, z_{ik})$. Тогда вероятности можно записать как:

$$\begin{aligned} \mathbb{P}(z_i = j \mid \Psi) &= \prod_{i=1}^k \omega_j^{z_{ij}} \\ \mathbb{P}(x_i \mid z_i = j, \Psi) &= \prod_{i=1}^k (f_j(x_i \mid \theta_j))^{z_{ij}} \end{aligned}$$

Итоговая совместная плотность:

$$\mathbb{P}(x_i, z_i = j \mid \Psi) = \left(\prod_{i=1}^k \omega_j^{z_{ij}} \right) \left(\prod_{i=1}^k f_j(x_i \mid \theta_j) \right) = \prod_{i=1}^k (\omega_j \cdot f_j(x_i \mid \theta_j))^{z_{ij}}$$

Поэтому правдоподобие полных данных равно:

$$\mathcal{L}_c(x, z \mid \Psi) = \prod_{i=1}^n \prod_{j=1}^k (\omega_j \cdot f_j(x_i \mid \theta_j))^{z_{ij}}$$

Стандартно, работаем с логарифмом правдоподобия [1] (см. уравнение 2.26):

$$\ln \mathcal{L}_c(x, z \mid \Psi) = \sum_{i=1}^n \sum_{j=1}^k z_{ij} \cdot (\ln \omega_j + \ln f_j(x_i \mid \theta_j))$$

0.3. Q-функция

Однако в обычных условиях мы не знаем z_{ij} . Пусть Z_{ij} — случайные величины соответствующие z_{ij} . Тогда введём Q-функцию [1] (см. уравнение 2.27):

$$Q(\Psi \mid \Psi^{(k)}) = \mathbb{E}_{Z|x, \Psi^{(k)}}[\ln \mathcal{L}_c(x, Z \mid \Psi)]$$

Оператор матожидания линеен, так что можем расписать:

$$Q(\Psi \mid \Psi^{(k)}) = \sum_{i=1}^n \sum_{j=1}^k \mathbb{E}[Z_{ij} \mid x, \Psi^{(k)}] \cdot (\ln \omega_j + \ln f_j(x_i \mid \theta_j))$$

Z_{ij} — бинарная случайная величина, поэтому ее матожидание равно:

$$\mathbb{E}[Z_{ij} \mid x, \Psi^{(k)}] = P(Z_{ij} = 1 \mid x_i, \Psi^{(k)})$$

По формуле Байеса эта величина равна:

$$P(Z_{ij} = 1 \mid x_i, \Psi^{(k)}) = \frac{\omega_j^{(k)} \cdot f_j(x_i \mid \theta_j^{(k)})}{\sum_{j=1}^k \omega_j^{(k)} \cdot f_j(x_i \mid \theta_j^{(k)})}$$

Обозначим эту величину за $\gamma_{ij}^{(k)}$, тогда:

$$Q(\Psi \mid \Psi^{(k)}) = \sum_{i=1}^n \sum_{j=1}^k \gamma_{ij}^{(k)} \cdot (\ln \omega_j + \ln f_j(x_i \mid \theta_j))$$

Стоит отметить, что итерация ЕМ алгоритма путём оптимизации Q-функции эквивалентна оптимизации логарифма правдоподобия [2].

0.4. Покомпонентная оптимизация Q-функции

Имеем:

$$Q(\Psi \mid \Psi^{(k)}) = \sum_{i=1}^n \sum_{j=1}^k \gamma_{ij}^{(k)} \cdot (\ln \omega_j + \ln f_j(x_i \mid \theta_j))$$

Разделим на две суммы:

$$Q(\Psi \mid \Psi^{(k)}) = \sum_{i=1}^n \sum_{j=1}^k \gamma_{ij}^{(k)} \cdot \ln \omega_j + \sum_{i=1}^n \sum_{j=1}^k \gamma_{ij}^{(k)} \ln f_j(x_i \mid \theta_j)$$

Понятно что первое и второе слагаемое можно оптимизировать независимо. Рассмотрим второе слагаемое и поменяем в нем порядок суммирования:

$$\sum_{i=1}^n \sum_{j=1}^k \gamma_{ij}^{(k)} \ln f_j(x_i \mid \theta_j) = \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij}^{(k)} \ln f_j(x_i \mid \theta_j)$$

Очевидно что если рассмотреть для каждого индекса j то получаем функции независящие друг от друга.

Список литературы

1. *McLachlan G. J., Peel D.* Finite Mixture Models. — New York : John Wiley & Sons, Inc., 2000. — С. 464. — (Wiley Series in Probability and Statistics). — ISBN 978-0-471-00626-8.
2. *Dempster A. P., Laird N. M., Rubin D. B.* Maximum Likelihood from Incomplete Data Via the EM Algorithm // Journal of the Royal Statistical Society: Series B (Methodological). — 2018. — Дек. — Т. 39, № 1. — С. 1—22. — ISSN 0035-9246. — DOI: 10.1111/j.2517-6161.1977.tb01600.x. — eprint: https://academic.oup.com/jrsssb/article-pdf/39/1/1/49117094/jrsssb_39_1_1.pdf. — URL: <https://doi.org/10.1111/j.2517-6161.1977.tb01600.x>.